Sistema Inteligente de Predicción Climática para la Optimización Agrícola en Antioquia: Un Enfoque de Analítica de Datos, Business Intelligence y Aprendizaje Automático

Luisa Fernanda Franco Carmona

Andrés Martínez Carvajal

Wilson Castañeda

Alexander Velez

Talento Tech – Bootcamp en Análisis de Datos

Nivel Integrador

Fecha de entrega: . 8 de abril de 2026]

Resumen iv

Abstract v

1. Introducción 1

2. Planteamiento del problema 3

3. Pregunta de investigación 4

4. Justificación 5

5. Objetivos 6

5.1 Objetivo general 6

5.2 Objetivos específicos 6

6. Estado del arte y marco conceptual 7

7. Metodología 9

7.1 Recolección de datos 9

7.2 Limpieza y preprocesamiento 9

7.3 Exploración y análisis de datos 10

7.4 Ingeniería de características 10

7.5 Modelado predictivo 10

7.6 Integración del sistema 11

7.7 Desarrollo y despliegue 11

8. Arquitectura e implementación técnica 12

9. Resultados 14

9.1 Desempeño predictivo 14

9.2 Optimización y despliegue 14

9.3 Visualización analítica 15

9.4 Hallazgos relevantes 15

10. Discusión 16

11. Conclusiones 18

12. Recomendaciones y trabajo futuro 19

Referencias 21

Resumen

El presente trabajo desarrolla una solución tecnológica orientada al sector agrícola del departamento de Antioquia, basada en analítica de datos, Business Intelligence y aprendizaje automático. El objetivo principal consiste en reducir la incertidumbre asociada a la variabilidad climática mediante la integración de datos meteorológicos históricos del IDEAM y registros agropecuarios relacionados con el rendimiento de cultivos. La propuesta articula una arquitectura de cuatro capas: ingesta de datos, almacenamiento en base de datos relacional, modelado predictivo en Python y visualización interactiva mediante Streamlit. Para la fase predictiva se implementó un modelo de **Random Forest Regressor**, adecuado para datos tabulares y capaz de capturar relaciones no lineales entre variables climáticas y geográficas. El sistema permite al usuario consultar un municipio y una fecha específica para obtener una estimación de temperatura máxima y una métrica de oscilación térmica, facilitando procesos de planeación agrícola. Los resultados muestran un desempeño satisfactorio del modelo, con un **R^2 de 0.74** y un **MAE de 1.36 °C**, además de una optimización del archivo del modelo de más de 100 MB a menos de 15 MB, favoreciendo el despliegue en la nube. Se concluye que la combinación entre datos históricos, infraestructura cloud y modelos supervisados constituye una alternativa viable para apoyar la toma de decisiones en contextos agroclimáticos regionales.

Palabras clave: analítica de datos, aprendizaje automático, agricultura, Business Intelligence, predicción climática, Antioquia, Random Forest.

Abstract

This paper presents a technological solution for the agricultural sector in the department of Antioquia, based on data analytics, business intelligence, and machine learning. The main objective is to reduce uncertainty associated with climate variability by integrating historical meteorological data from IDEAM and agricultural records related to crop performance. The proposal is built on a four-layer architecture: data ingestion, relational database storage, predictive modeling in Python, and interactive visualization through Streamlit. A **Random Forest Regressor** was implemented for the predictive stage, as it is suitable for tabular data and capable of capturing nonlinear relationships among climatic and geographic variables. The system allows users to select a municipality and a specific date to obtain an estimated maximum temperature and a thermal oscillation metric, supporting agricultural planning processes. Results show satisfactory model performance, with an **R^2 of 0.74** and a **MAE of 1.36 °C**, as well as model compression from more than 100 MB to less than 15 MB, improving cloud deployment. It is concluded that the combination of historical data, cloud infrastructure, and supervised models is a viable alternative to support decision-making in regional agroclimatic contexts.

Keywords: data analytics, machine learning, agriculture, Business Intelligence, climate prediction, Antioquia, Random Forest.

1. Introducción

La agricultura constituye una actividad estratégica para el desarrollo económico y social del departamento de Antioquia. Sin embargo, su productividad se encuentra altamente condicionada por el comportamiento del clima, especialmente por variables como temperatura, precipitación y radiación solar. En escenarios de variabilidad climática, las decisiones relacionadas con la siembra, el manejo agronómico y la cosecha suelen tomarse con información incompleta o tardía, lo que incrementa el riesgo productivo y financiero.

En Colombia, el acceso a información meteorológica oficial ha mejorado mediante plataformas institucionales como el sistema DHIME del IDEAM, que permite la consulta y gestión de datos hidrológicos y meteorológicos. De forma complementaria, AGROSAVIA y el portal nacional de datos abiertos ofrecen conjuntos de datos vinculados al análisis agropecuario, suelos, análisis foliares y rendimiento de cultivos, lo que abre oportunidades para integrar fuentes diversas en soluciones de analítica aplicada al agro. Source Source

En paralelo, el desarrollo de herramientas de ciencia de datos y visualización interactiva ha permitido que modelos de aprendizaje automático puedan integrarse en aplicaciones accesibles para usuarios no técnicos. Frameworks como Streamlit facilitan la construcción de aplicaciones multipágina, mientras que plataformas como Streamlit Community Cloud simplifican su despliegue público. Asimismo, infraestructuras como Railway permiten aprovisionar bases de datos MySQL con baja complejidad operativa. Source Source Source

En este contexto, el presente proyecto propone un sistema inteligente de predicción climática orientado a la optimización agrícola en Antioquia. La solución combina datos históricos, modelado predictivo y visualización analítica para apoyar la toma de decisiones de productores, técnicos y gestores del sector.

2. Planteamiento del problema

Los productores agrícolas del departamento de Antioquia enfrentan una problemática recurrente: la incertidumbre climática afecta directamente el rendimiento de los cultivos y la eficiencia en la planificación agrícola. Fenómenos como El Niño y La Niña alteran los patrones habituales de temperatura y precipitación, generando pérdidas económicas, reducción de productividad y mayor exposición al riesgo.

Aunque existen datos oficiales sobre clima y agricultura, estos suelen estar dispersos, en formatos técnicos o poco accesibles para la toma de decisiones operativas. La ausencia de una herramienta integrada que relacione variables climáticas históricas con comportamiento productivo limita la capacidad de anticipación y de análisis estratégico por parte de los actores del sector.

Por tanto, surge la necesidad de construir una solución que transforme datos brutos en conocimiento útil, interpretable y aplicable, mediante técnicas de analítica de datos e inteligencia artificial.

3. Pregunta de investigación

¿En qué medida un modelo de aprendizaje automático puede reducir la incertidumbre climática para los productores agrícolas en el departamento de Antioquia utilizando datos históricos del IDEAM?

4. Justificación

Este proyecto se justifica desde tres dimensiones. En primer lugar, desde la dimensión **social y productiva**, porque contribuye a democratizar el acceso a herramientas de analítica avanzada en un sector tradicionalmente expuesto a la incertidumbre climática. En segundo lugar, desde la dimensión **tecnológica**, porque evidencia cómo la integración de bases de datos, machine learning y visualización web puede traducirse en soluciones funcionales para entornos reales. Finalmente, desde la dimensión **académica**, porque permite aplicar de manera articulada conocimientos de estadística, ciencia de datos, inteligencia artificial e ingeniería de software en un caso de uso concreto.

La relevancia del proyecto aumenta al considerar que el aprendizaje estadístico se ha consolidado como un conjunto de herramientas fundamentales para comprender datos complejos y construir modelos predictivos aplicables en diversos campos, incluido el sector agropecuario. Source

5. Objetivos

5.1 Objetivo general

Desarrollar una solución tecnológica integral basada en análisis de datos y aprendizaje supervisado para el pronóstico climático y la optimización de la toma de decisiones en el sector agrícola de Antioquia.

5.2 Objetivos específicos

1. Correlacionar variables climáticas históricas, tales como temperatura, precipitación y brillo solar, con el rendimiento agrícola observado en los cultivos.
2. Implementar una arquitectura de datos robusta utilizando MySQL para almacenamiento y Python para procesamiento analítico.
3. Desarrollar y ajustar un modelo de aprendizaje automático capaz de estimar variaciones térmicas futuras.
4. Diseñar una interfaz interactiva en Streamlit que facilite la interpretación de resultados por parte de usuarios no técnicos.
5. Proporcionar información útil para apoyar decisiones de planeación agrícola basadas en evidencia.

6. Estado del arte y marco conceptual

El aprendizaje automático aplicado a problemas predictivos sobre datos tabulares ha mostrado resultados sólidos en escenarios donde intervienen múltiples variables explicativas. Entre los algoritmos más utilizados se encuentra **Random Forest**, definido por scikit-learn como un metaestimador que ajusta múltiples árboles de decisión sobre submuestras del conjunto de datos y utiliza el promedio para mejorar la precisión predictiva y controlar el sobreajuste. Esta propiedad resulta especialmente valiosa en contextos donde existen relaciones no lineales y ruido en los datos. Source

Desde una perspectiva metodológica, James et al. (2021) destacan que los métodos de aprendizaje estadístico permiten modelar fenómenos complejos y mejorar procesos de predicción a partir de datos observados. Dicho enfoque ha sido ampliamente utilizado en aplicaciones de clasificación, regresión y análisis exploratorio, con gran potencial para resolver problemas del sector agrícola. Source Source

En cuanto al componente de visualización y despliegue, Streamlit se ha consolidado como una herramienta eficaz para transformar modelos y análisis en aplicaciones web interactivas. Su documentación oficial señala que las aplicaciones multipágina pueden organizarse por directorios o mediante navegación programática, favoreciendo el diseño modular de soluciones analíticas. Source

Por otra parte, la gestión de datos y artefactos técnicos en proyectos de ciencia de datos suele requerir herramientas complementarias. MySQL Connector/Python ofrece un controlador oficial para la comunicación entre aplicaciones Python y servidores MySQL, mientras que Git LFS permite versionar archivos grandes, como modelos serializados, sin sobrecargar el repositorio principal. Source Source

7. Metodología

La metodología del proyecto siguió un enfoque aplicado, secuencial e iterativo, estructurado en varias fases.

7.1 Recolección de datos

Se utilizaron datos meteorológicos históricos del IDEAM como fuente principal para el componente climático del proyecto. Paralelamente, se tomaron referencias agropecuarias y registros abiertos asociados a cultivos y rendimiento agrícola provenientes de AGROSAVIA y del portal de datos abiertos de Colombia. Esta combinación permitió construir una base analítica orientada al estudio de la relación entre clima y producción. Source Source

7.2 Limpieza y preprocesamiento

La información recolectada fue tratada mediante **Pandas** y consultas SQL. En esta etapa se corrigieron valores nulos, se revisaron registros atípicos, se estandarizaron formatos de fecha y se normalizaron los identificadores de municipios. El propósito fue garantizar consistencia entre fuentes y generar una base confiable para el entrenamiento del modelo.

7.3 Exploración y análisis de datos

Se realizó un análisis exploratorio para comprender la distribución de las variables, identificar patrones de variabilidad térmica y detectar correlaciones entre las variables climáticas y el comportamiento de los cultivos. Esta fase permitió seleccionar atributos relevantes y comprender mejor la dinámica de los datos.

7.4 Ingeniería de características

Se transformaron variables temporales y geográficas en características útiles para el modelo. Un hallazgo importante fue la incorporación de **Municipio_ID** como variable numérica, lo que fortaleció la capacidad del sistema para capturar patrones geográficos asociados al comportamiento térmico.

7.5 Modelado predictivo

Para la estimación de temperatura máxima futura se implementó un modelo de **Random Forest Regressor** en Python. La elección de este algoritmo se sustentó en su robustez frente a datos tabulares, su capacidad para manejar relaciones complejas y su equilibrio entre interpretabilidad y rendimiento. De acuerdo con la documentación oficial de scikit-learn, este modelo mejora la precisión mediante la agregación de múltiples árboles y reduce el riesgo de sobreajuste. Source

7.6 Integración del sistema

La solución completa se estructuró en una arquitectura de cuatro capas:

1. **Ingesta:** extracción de datos desde fuentes oficiales.
2. **Almacenamiento:** carga y normalización en una base de datos MySQL alojada en la nube.
3. **Inteligencia:** entrenamiento y consulta del modelo en Python.

4. **Presentación:** visualización e interacción mediante una aplicación multipágina en Streamlit.

7.7 Desarrollo y despliegue

El entrenamiento inicial se realizó en **Google Colab**, mientras que el desarrollo e integración del sistema se llevó a cabo en **Visual Studio Code**. Para el control de versiones se utilizó **GitHub**, junto con **Git LFS** para manejar artefactos pesados como archivos .pkl. La aplicación fue publicada a través de **Streamlit Community Cloud**, que ofrece un flujo de despliegue simplificado conectado al repositorio del proyecto. Source Source

8. Arquitectura e implementación técnica

El sistema funciona como un consultor virtual de apoyo a la planificación agrícola. Desde la perspectiva del usuario, el flujo es simple: seleccionar un municipio y una fecha. Sin embargo, internamente la solución activa una secuencia organizada de procesos.

Primero, la aplicación recibe la entrada del usuario desde la interfaz web. Luego, el sistema transforma dicha entrada al formato requerido por el modelo, relacionando municipio, temporalidad y variables asociadas. Posteriormente, el modelo procesa la información y genera una estimación de temperatura máxima, acompañada de una métrica de oscilación térmica. Finalmente, el resultado se visualiza mediante indicadores, gráficas y componentes interactivos.

La base de datos del sistema se implementó en MySQL. La documentación de Railway establece que su plantilla MySQL permite aprovisionar una base con configuración mínima y conectar servicios mediante variables de entorno, lo cual se ajusta a una arquitectura cloud-native ligera. Source

La conexión entre Python y MySQL se soportó mediante **MySQL Connector/Python**, definido oficialmente como un controlador autocontenido para desarrollar aplicaciones de base de datos con Python. Source

En el nivel de interfaz, Streamlit ofreció soporte para estructurar una aplicación multipágina, separando el módulo de predicción del módulo de análisis exploratorio. Esta separación mejoró la claridad funcional de la herramienta y favoreció su uso por perfiles no técnicos. Source

9. Resultados

Los resultados del proyecto pueden analizarse en tres dimensiones: desempeño del modelo, eficiencia técnica del sistema y valor aplicado para el análisis de datos.

9.1 Desempeño predictivo

El modelo alcanzó un **coeficiente de determinación R^2 de 0.74** y un **Error Medio Absoluto (MAE) de 1.36 °C**. Estos indicadores sugieren que la solución presenta una capacidad predictiva adecuada para apoyar decisiones en escenarios agrícolas, particularmente en tareas de estimación térmica donde pequeñas variaciones pueden ser relevantes para la gestión de cultivos.

9.2 Optimización y despliegue

Uno de los logros técnicos más importantes fue la compresión del modelo entrenado, pasando de un tamaño superior a **100 MB** a menos de **15 MB**. Esta reducción permitió mejorar la viabilidad del despliegue en la nube, disminuir tiempos de carga y favorecer una experiencia de uso más fluida en Streamlit Cloud.

9.3 Visualización analítica

Se desarrollaron dashboards interactivos que incluyeron:

- **Gráficos de caja (boxplots):** para estudiar la variabilidad térmica por municipio.
- **Gráficos de dispersión:** para analizar la relación entre variables predictoras.
- **Métricas dinámicas:** para mostrar indicadores en tiempo real derivados de la predicción.

Estas visualizaciones permitieron no solo consumir el resultado del modelo, sino también interpretar el comportamiento histórico de los datos y detectar posibles anomalías climáticas.

9.4 Hallazgos relevantes

Se identificó que la incorporación del identificador municipal como variable numérica fortaleció la capacidad de aprendizaje del modelo respecto al contexto geográfico. Asimismo, la arquitectura basada en servicios cloud y herramientas open source demostró ser suficiente para construir una solución funcional, escalable y adecuada para un proyecto formativo con proyección real.

10. Discusión

Los resultados obtenidos muestran que el uso de aprendizaje automático en contextos agroclimáticos regionales es técnicamente viable y metodológicamente pertinente. Si bien el sistema no sustituye los pronósticos meteorológicos oficiales, sí aporta una capa adicional de inteligencia para la planeación productiva, basada en patrones históricos y relaciones multivariadas.

El valor principal del proyecto radica en su enfoque integrador. No se limita al entrenamiento de un modelo, sino que articula gestión de datos, almacenamiento estructurado, visualización accesible y despliegue funcional. Esta integración es esencial para convertir una solución de ciencia de datos en una herramienta de uso real.

Además, el proyecto evidencia que las plataformas y librerías actuales reducen significativamente las barreras de implementación. Streamlit permite materializar análisis en interfaces interactivas; Railway simplifica la provisión de bases de datos; Git LFS resuelve el manejo de artefactos grandes; y scikit-learn provee modelos confiables y documentados. Source Source Source Source

Sin embargo, el proyecto también presenta limitaciones. La capacidad predictiva depende de la calidad, cobertura y actualización de los datos históricos. Además, el enfoque basado en Random Forest, aunque robusto, no modela explícitamente dependencias temporales de largo plazo como sí podrían hacerlo modelos de series temporales o redes neuronales recurrentes.

11. Conclusiones

En primer lugar, se concluye que la integración entre analítica de datos, inteligencia artificial y visualización interactiva permitió construir una solución funcional para apoyar la toma de decisiones agrícolas en Antioquia.

En segundo lugar, el modelo de **Random Forest Regressor** resultó apropiado para el problema planteado, ofreciendo un desempeño satisfactorio y confirmando la utilidad de los métodos supervisados en escenarios con datos tabulares multivariados. Source

En tercer lugar, la variable geográfica representada por **Municipio_ID** mejoró la capacidad del modelo para capturar diferencias territoriales, lo que sugiere que la dimensión espacial es determinante en el análisis agroclimático regional.

En cuarto lugar, el despliegue cloud-native mediante GitHub, MySQL y Streamlit demostró que es posible construir herramientas escalables y accesibles con tecnologías abiertas y de aprendizaje relativamente rápido. Source Source

Finalmente, el proyecto confirma que el aprovechamiento de datos históricos oficiales constituye un recurso estratégico para reducir incertidumbre, anticipar riesgos y fortalecer la resiliencia del sector agropecuario.

12. Recomendaciones y trabajo futuro

Se recomienda ampliar la solución en varias direcciones. Primero, integrar datos en tiempo real mediante sensores IoT o servicios automáticos de actualización climática. Segundo, añadir un módulo de recomendación de cultivos basado no solo en temperatura, sino también en precipitación y otras variables agroambientales. Tercero, evaluar modelos de series temporales, como Prophet o LSTM, para mejorar la capacidad de pronóstico de mediano y largo plazo. Cuarto, incorporar mecanismos de validación continua del modelo en producción, de modo que la herramienta pueda recalibrarse a medida que cambien las condiciones climáticas o se disponga de nuevas observaciones.

Asimismo, sería pertinente fortalecer la dimensión de usabilidad con perfiles diferenciados de usuario, exportación de reportes y sistemas de alertas tempranas para toma de decisiones más inmediata.

Referencias

AGROSAVIA. (s. f.). *Datos abiertos*. https://www.agrosavia.co/nosotros/transparencia-y-acceso-a-información-pública/datos-abiertos

GitHub Docs. (s. f.). *Configuring Git Large File Storage*. https://docs.github.com/en/repositories/working-with-files/managing-large-files/configuring-git-large-file-storage

IDEAM. (s. f.). *DHIME: Sistema de información para la gestión de datos hidrológicos y meteorológicos*. https://www.ideam.gov.co/dhime

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An introduction to statistical learning: With applications in R* (2nd ed.). Springer. https://link.springer.com/book/10.1007/978-1-0716-1418-1

MySQL. (2024). *MySQL Connector/Python Developer Guide*. https://dev.mysql.com/doc/connector-python/en/

Railway. (s. f.). *MySQL*. Railway Docs. https://docs.railway.com/databases/mysql

Scikit-learn Developers. (s. f.). *RandomForestRegressor*. https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestRegressor.html

Streamlit. (s. f.-a). *Multipage apps*. https://docs.streamlit.io/develop/concepts/multipage-apps

Streamlit. (s. f.-b). *Prep and deploy your app on Community Cloud*. https://docs.streamlit.io/deploy/streamlit-community-cloud/deploy-your-app

StatLearning. (s. f.). *An introduction to statistical learning*. https://www.statlearning.com/

Anexos

- URL Video en Youtube https://youtu.be/-Ztuqg3BG4Q
- Modelo Entidad–Relación (MER) generado en MySQL.(Github)
- Script SQL de la base de datos.(Github)
- Conjunto de datos sintéticos utilizados.(Se utilizaron datos de los siguiente enlaces : https://www.ideam.gov.co/datos-abiertos, https://www.datos.gov.co/browse?q=agricultura&sortBy=relevance&page=1&pageSize=20)
- Consultas SQL implementadas.(Github)
- Dashboard desarrollado en Streamlit.Url Aplicativo Streamlit : https://landingpageclima.streamlit.app/
- Repositorio completo cargado en GitHub. Url Github : https://github.com/grupoproyectoanalisisdatos-bot/Simulacion_-IA-cosechas_-repo-prueba-streamlit.git
- Url Landing page : https://grupoproyectoanalisisdatos-bot.github.io/Simulacion_-IA-cosechas_-repo-prueba-streamlit/

- Captura de la Landing page